
面向招聘场景的局部特征投影语义匹配框架

Yinghao Jiao
yinghaojiao@careerintlinc.com

Austin Wang
AustinWang@careerintlinc.com

Mac Liu
Macliu@careerintlinc.com

Abstract

招聘场景下，技术类岗位与简历的核心匹配要素取决于技能词，与技能词位置和非技能描述文本无关，现有匹配方法常受上述因素影响。针对该问题，本文设计了一种基于 CNN[4] 的局部特征投影架构，融合全局语义和多粒度局部特征，从而有效捕获技能词的组合模式。实验基于真实场景中的 6 万人岗训练数据微调。结果表明，相较于基线 CRE 模型，该方法在三种语义相似度任务（岗岗、人岗、人人）中实现 2.1% 的性能提升，在抗噪声鲁棒性任务中实现 2.4% 提升；消融实验进一步证实，层次化卷积核组件能够强化 CLS 向量局部特征编码能力，证明了利用神经网络组件可以优化招聘场景语义检索任务。

1 引言

中高端招聘对顾问的岗位知识要求尤为严苛，面对市场的瞬息万变，招聘顾问迅速掌握岗位知识和市场动态成为制约招聘效率的关键因素。据科锐国际以往数据显示，顾问要熟练掌握一个新领域，通常需要长达两年的时间。如何缩短顾问岗位知识学习周期，适应中高端招聘市场的快速变化，成为模型重点突破的方向。

招聘场景中的文本（如职位描述或简历）区别于其他类型文本，不需要从头到尾阅读，通常采用扫视阅读，因此在模型架构设计时应更关心局部关系。然而，现有的文本嵌入模型 (SimCSE[3]) 无法准确解决招聘领域中的局部关系语义匹配，职位描述表述会更抽象化，而简历表述更具体。同时，招聘领域文本中往往同时出现通用技能词与领域核心技能词，导致岗岗、人岗、人人匹配场景的准确度受到影响。我们将这种问题定义为技能词上下位匹配问题。

此外，文本嵌入模型在处理某些场景（如职位描述的语义不变而部分技能词顺序变化）时，其匹配（的排序）结果会发生较大的变化，我们将这种现象定义为查询鲁棒性问题。研究表明，这种语义鲁棒性问题在文本匹配任务中普遍存在 [7]，特别是在处理技能词组合和位置变化时尤为明显。

以人岗匹配任务为例，在图 1 中，职位中的技能词（如“配送场景算法设计”）和简历中的技能词（如“路径规划算法”）有上下位匹配关系并且不受位置影响。在复杂的实际场景中，模



图 1: 岗岗匹配描述示例

型难以有效捕获技能词的上下位关系和局部模式，导致匹配结果不准确。这种语义建模的局限性在人岗匹配（简历与职位的语义对齐）及人人匹配任务中同样存在，是招聘匹配场景的核心技术瓶颈。

神经网络的 CNN 组件具备局部性和平移不变性等特质，局部性通过受限感受野机制聚焦细粒度技能实体的组合模式，平移不变性有效消解词序扰动对语义表征的影响，这与岗位技能上下位匹配问题和查询鲁棒性问题形成理论映射。我们在 BERT[2] 架构的基础上，引入 CNN[5, 11] 来优化招聘领域匹配场景中的问题。具体而言，通过 CNN 的局部稀疏连接特性，对 CRE（科锐人力资源招聘领域嵌入模型）最后一层输出的表征进行局部特征增强，通过构建多尺度卷积核，在保持特征等变性（局部语义 + 位置无关）的同时，捕获技能术语的跨窗口组合规律（如“配送范围算法 路径规划算法”）。利用权值共享机制诱导的平移不变性构建多位置采样特征提取器，来抑制文本表述变异（如技能项置换、修饰语增删），提升模型对查询的鲁棒性。本文的主要贡献可以总结如下：

1. 对齐框架：基于孪生双塔编码器框架 [8]，通过 BERT 和 CNN 的组合网络实现语义对齐，有效解决多场景中（岗岗、人岗、人人）的技能词上下位匹配问题。
2. CNN 局部特征投影：通过 CNN 辅助模块优化 BERT 的特征表达能力，强制模型学习更鲁棒的上下文特征，促使 BERT 在微调时兼顾全局语义与局部特征，CNN 层在此过程中仅作为训练阶段压缩特征的投影工具。
3. 多粒度表征：通过递减卷积核序列捕获不同粒度的局部特征，结合分层最大池化，实现技能术语的粒度抽象，提取不同粒度的语义信息。

2 相关工作

在人员-职位匹配领域，Zhu 等人 [13] 提出了人员与职位匹配神经网络 (PJFNN)，一种基于卷积神经网络 (CNN) 的端到端模型。PJFNN 将职位发布和简历分别映射到共享的潜在表征上，并通过学习历史求职申请数据中的联合表征，来评估候选人与职位的匹配程度。TAROT[12] 利用 LinkedIn 上的大规模用户档案和职位描述数据，采用分层结构进行多层次多粒度共同预训练，包括句子级别、部分级别（如摘要、教育经历等）、个体级别、交互级别，有效提升了

模型的表达能力和信息量。然而，这些方法在处理技能词上下位关系时存在以下局限性：1) 缺乏对局部语义特征的细粒度建模，难以有效捕获技能词之间的组合模式；2) 对文本表述的变异性（如词序变化、修饰语增删）缺乏鲁棒性；3) 在跨领域迁移时性能下降明显。本文提出的局部特征投影架构通过多尺度特征提取和动态特征融合机制，有效解决了上述问题。

投影层特指将高维上下文表征（如 **CLS** 向量）映射至任务特定空间的转换模块 [8]。其核心功能包括：特征聚合：通过平均池化或最大池化操作，将序列级表征压缩为句向量 [1]。语义降维：利用全连接层实现高维空间（如 1024 维）之间的非线性映射，抑制冗余噪声，提升模型表达能力 [3]。领域适配：在微调阶段调整投影层参数，使预训练语义空间与下游任务对齐 [2]。Yann LeCun 在自监督学习手册中指出，投影层的设计对模型性能有重要影响，投影层能够有效地将特征映射到统一的语义空间中 [6]。然而，传统的投影层设计存在以下不足：1) 静态的特征聚合方式难以适应不同粒度的语义信息；2) 简单的线性变换无法有效建模技能词之间的复杂关系；3) 缺乏对局部特征的显式建模 [7]。本文通过引入 **CNN** 动态特征增强机制，实现了对多粒度语义特征的层次化建模，并通过残差连接保持了对原始语义信息的访问，有效提升了模型的表征能力。

在科锐国际，我们基于 **CRE0.4.1** 模型在业务系统中实现了混合检索功能，混合检索主要包含字面检索与语义检索，利用 **LLM** 模型的世界知识，我们从查询条件中提取多粒度关键词，以此成为字面检索的召回条件，配合语义检索，我们发现这种实验的效果远好于单纯利用 **CRE0.4.1** 的语义检索，也侧面论证了招聘场景中的局部性，我们将这个系统命名为匹配系统，它为我们研究招聘场景的局部性和鲁棒性提供了实验依据。

3 方法

3.1 问题定义

在招聘领域文本匹配任务中，文本序列表示为： $x = [w_1, \dots, w_T] \in V^T$ ，包含技能片段 $s_k = [w_t, \dots, w_{t+\Delta}]$ ，技能术语集合： $S = \{s_k\}_{k=1}^n$ ，其中存在上下位关系 $R = \{(s_p, s_c) \mid s_p \prec s_c\}$ 。我们可以将技能术语集合 S 与上下位关系 R ，以卷积公式适配至文本匹配任务，定义层次化一维卷积：

$$[\mathbf{H}^{(l)}]_t = u^{(l)} + \sum_{\delta=-\Delta}^{\Delta} [\mathbf{V}^{(l)}]_{\delta} \cdot [\mathbf{X}^{(l-1)}]_{t+\delta}$$

其中 Δ 控制 **n-gram** 技能组合的感知范围（如 $\Delta = 5$ 捕获 **5-gram** 模式），通过多层级卷积 ($l = 1, 2$) 实现技能上下位的约束，通过卷积的局部性覆盖技能术语组合。

将对抗鲁棒性目标：

$$R_{robust}(f) = \min_{f \in \mathcal{F}} \frac{1}{n} \sum_{i=1}^n \max_{\|x_i - x'_i\|_{\infty} < \epsilon} \mathcal{L}(f(x'_i), y_i)$$

适配至招聘文本匹配场景， x'_i 为保语义词序扰动（如交换技能项顺序），相似性约束控制在 ϵ 以内。通过 **CNN** 的平移不变性，本方案将对抗鲁棒性问题转化为结构归纳偏置约束下的优化问题。

该架构基于以下三个核心设计理念：对齐框架、动态特征增强和多粒度表征，以解决技能词上下位匹配和查询鲁棒性问题。具体而言：

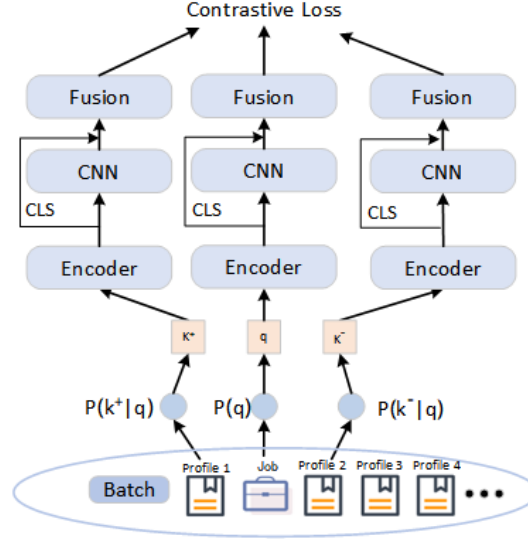


图 2: 模型架构图

3.2.1 对齐架构

如图 2 所示, 我们采用孪生双塔编码器框架 [8] 作为基础架构, 使用 CRE0.4.1 作为编码器主体, 它是基于 BERT 的预训练模型, 专门针对中文简历和职位描述的匹配任务进行了优化。通过双塔结构, 模型能够同时编码查询文本和候选文本, 实现跨场景 (岗岗、人岗、人人) 的语义对齐。在每个编码器中, 我们保留了 BERT 的原生结构以获取全局语义表征, 并在此基础上引入了 CNN 增强模块以捕获局部特征模式。

为了优化双塔结构的语义对齐能力，我们采用 InfoNCE 对比损失函数：

$$\mathcal{L}_{\text{con}} = -\log \frac{\exp(\text{sim}(\mathbf{h}_i, \mathbf{h}_i^+)/\tau)}{\sum_{j=1}^K \exp(\text{sim}(\mathbf{h}_i, \mathbf{h}_j^-)/\tau)}$$

其中, $\text{sim}(\cdot, \cdot)$ 表示余弦相似度函数, \mathbf{h}_i 和 \mathbf{h}_i^+ 分别表示查询文本和正样本的表征向量, \mathbf{h}_j^- 表示负样本的表征向量, τ 为温度系数 (设置为 0.1) 用于调节困难样本的权重。这种对比学习策略能够有效地强制不同词序的局部特征在向量空间中对齐, 提升模型对文本表述变化的鲁棒性。

3.2.2 局部特征投影

为优化模型的特征表达能力，我们设计了基于 CNN 的局部特征投影架构，如图 3 所示。该机制主要包含以下组件：

- **局部特征提取**：采用多尺度卷积核（3、5）扫描输入序列，通过局部感受野机制捕获不同长度的 **n-gram** 级别语义特征。这种设计特别适合处理技能词的组合关系，如"配送范围算法"与"路径规划算法"之间的语义映射。




图 3: 局部特征投影架构示意图

- 特征融合网络：通过门控机制对不同尺度的卷积特征进行动态融合。通过可学习的门控单元，模型能够根据输入文本的特点自适应地调整各个尺度特征的权重，实现特征的自适应组合。
- 残差连接：在 CNN 增强层和原始 CLS 表征之间建立短路连接，确保模型能够保持对原始语义信息的访问。这种设计不仅缓解了深度网络的优化问题，还为模型提供了一个可选的信息通路。

3.2.3 多粒度表征

为实现技能词的多粒度语义理解，我们采用了层次化的特征提取策略 [9]：

- 递减卷积核序列：通过设计递减尺寸的卷积核序列（从 5 到 3），逐层捕获不同粒度的局部特征。较大的卷积核关注更宽范围的语义组合，而较小的卷积核则专注于精细的词组关系。
- 分层最大池化：在每个卷积层后应用最大池化操作，提取最显著的特征并降低特征维度。这种分层池化策略有助于构建层次化的语义表示。
- 特征聚合：最终通过加权求和的方式将不同粒度的特征进行整合，得到一个综合的表征向量。权重参数通过端到端训练自动学习，使模型能够根据不同场景自适应地调整特征组合。

这种多层次的架构设计使模型能够同时处理不同抽象层次的语义信息，从而更好地理解技能词之间的上下位关系，并提高模型对文本表述变化的鲁棒性。

4 实验

4.1 实验设置

我们采用基于 BERT 架构的 CRE0.4.1 作为基座模型，使用 InfoNCE 损失函数进行训练，温度系数（temperature）设置为 0.1。在训练过程中，使用 4 个 GPU 并行训练，batch_size 设置为 64 并采用批内负样本策略，每 4 个 batch 进行一次梯度累积更新，学习率设为 $1e-5$ 。训练持续 10 个 epoch，选取测试集上表现最佳的 checkpoint 作为最终模型。对于模型初始化，门控单元的权重采用 Xavier 初始化（偏置项为 0.01），卷积层权重采用 Kaiming_normal 初始化（偏置项为 0）。训练完成后，移除新增的 CNN 模块，使用 CRE 最后一层的 CLS token embedding 作为句子表征。

4.2 下游任务

本文的微调策略在 6 万组人岗/岗岗匹配的训练数据上进行了评估。实验结果表明,引入 CNN 层的微调模型 CRE_cnn_ft 在技术类测试集上提升了 2.1 个百分点,证实了局部特征增强对技术类岗位匹配的有效性。由于招聘领域任务的复杂性,通用 Embedding 模型无法取得较好的效果, BGE[10] 等通用 Embedding 模型在 PJBenchmark 任务中表现较差。由此可见,招聘场景需要领域特定的 Embedding 模型,表 1 展示了测试结果。

表 1: CRE 历史版本 PJBenchmark 测试结果

Model	AVG	jd2jd	jd2cv	cv2cv
BGE	34.05	41.94	21.66	38.55
CRE 0.1.0	36.14	42.48	30.37	35.56
CRE 0.2.0	41.22	52.97	30.98	39.72
CRE 0.3.1	44.27	45.58	42.89	44.33
CRE 0.4.1	42.88	49.49	43.53	35.61
CRE_cnn_ft	44.99	50.42	46.25	38.29

为验证模型的领域泛化性,我们还进行了跨领域的对比实验,结果如表 2 所示。实验结果表明,该方法在金融和算法等不同领域同样具有良好的效果。

表 2: 领域泛化性测试结果

Model	Finance Domain	Algorithm Domain
CRE0.4.1	63.70	43.53
CRE_cnn_ft	65.84	46.25

4.3 鲁棒性测试

针对真实场景的特定例子,我们进行了鲁棒性实验。通过对 sentence1 进行语义不变的简短重述得到 sentence2,结果表明 CRE_cnn_ft 对句子对的整体相似度提升(约 2.4%),这意味着模型对非语义变化(如语句长短、表述方式的改变等)更鲁棒,更好地理解了语义。表 3 展示了鲁棒性实验结果。

表 3: 鲁棒性实验结果

Sentence1	Sentence2	CRE0.4.1	CRE_cnn_ft
负责配送范围等场景算法设计...	熟悉算法开发...	0.62	0.65
	熟悉深度学习...	0.61	0.64
	熟悉机器学习...	0.62	0.63
	熟悉数据分析...	0.52	0.56
	熟悉数据挖掘...	0.55	0.58
	熟悉统计分析...	0.57	0.61
	熟悉 NLP 算法...	0.64	0.66
	熟悉 CV 算法...	0.61	0.62

在文本噪声估计中，我们使用复旦大学的 TextFlint 检验模型 [7] 在 PJbenchmark 任务中对语义无关的标点符号变化的鲁棒性。结果表明4, CRE_cnn_ft 对标点扰动的抗干扰能力更强, 对查询的标点变化具有更好的鲁棒性。

表 4: TextFlint 鲁棒性测试结果

Model	Original	Perturbed
CRE0.4.1	43.53	43.32
CRE_cnn_ft	45.76	45.74

4.4 消融实验

为验证局部特征投影架构的有效性，我们设计了一系列消融实验，来确定 CNN 与 CRE 末层解冻策略的协同作用机制。表5展示了不同模型变体的实验结果。其中，CRE_cnn_ft (cls) 表示使用 CNN 增强并采用 cls token 作为句子表征的模型；CRE_ft (cls) 表示仅微调 CRE 末层并使用 cls token 的基线模型；CRE_v0.4.1 (pooler_output) 是使用原始 CRE 0.4.1 版本的 pooler 层输出；CRE_ft_pooling 表示在微调时使用常规池化层，分别基于 pooler_output 和 cls token 两种表征方式；CRE_ft_1792_pooling 则是将池化层维度扩展至 1792 的变体，同样包含基于 pooler_output 和 cls token 的两种实现。

表 5: 消融实验结果

Model	AVG	jd2jd	jd2cv	cv2cv
CRE_cnn_ft (cls)	44.99	50.42	46.25	38.29
CRE_ft (cls)	37.96	48.16	37.9	27.83
CRE_v0.4.1 (pooler_output)	41.97	49.73	41.85	34.34
CRE_ft_pooling (pooler_output)	37.95	49.79	38.29	25.77
CRE_ft_pooling (cls)	39.36	49.22	39.37	29.49
CRE_ft_1792_pooling (pooler_output)	36.49	47.56	35.54	26.36
CRE_ft_1792_pooling (cls)	38.05	48.24	37.48	28.44

实验结果表明：1. CRE_cnn_ft 在所有指标上都取得了最好的效果，验证了局部特征投影架构的有效性。2. 单纯的末层微调（CRE_ft）或使用常规 pooling 层的方案效果有限。3. 扩大 pooling 层维度（1792）反而导致性能下降，说明简单增加参数量并不能提升模型效果。4. cls token 相比 pooler_output 在大多数情况下表现更好，这验证了我们选择 cls token 作为句子表征的合理性。

5 结论

本研究提出一种基于卷积神经网络增强的层次化语义蒸馏框架，通过解冻 CRE 末层参数并构建多尺度 CNN 支路联合微调，通过全局语义与局部特征的动态融合指导 CRE 的 CLS 提升表征质量。我们在岗岗、人岗、人人三个招聘场景的不同任务中验证了其性能提升的价值，并通过语义不变的扰动测试验证了其查询鲁棒性的提升。该方法除了在技术类匹配中有效，在其他通用领域（如财务域）中同样适用。本方案基于 CRE 实现了高效参数微调（仅更新了 3.9% 参数），为优化人力资源招聘领域的匹配任务性能提供了新的思路。

致谢

本研究得到了公司内部各技术团队的鼎力支持，在此表示衷心的感谢。

参考文献

- [1] A. Conneau, D. Kiela, H. Schwenk, L. Barrault, and A. Bordes. Supervised learning of universal sentence representations from natural language inference data. In *Proceedings of the 2017 Conference on Empirical Methods in Natural Language Processing*, pages 670–680. Association for Computational Linguistics, 2017.
- [2] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv:1810.04805*, 2019.
- [3] T. Gao, X. Yao, and D. Chen. Simcse: Simple contrastive learning of sentence embeddings. *arXiv preprint arXiv:2104.08821*, 2021.
- [4] G. Huang, Z. Liu, L. Van Der Maaten, and K. Q. Weinberger. Densely connected convolutional networks. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 4700–4708, 2017.
- [5] Y. Kim. Convolutional neural networks for sentence classification. *arXiv preprint arXiv:1408.5882*, 2014.
- [6] Y. LeCun and I. Misra. Self-supervised learning cookbook. *arXiv preprint arXiv:2304.12210*, 2023.
- [7] Y. Liu, M. Ott, N. Goyal, J. Du, M. Joshi, D. Chen, O. Levy, M. Lewis, L. Zettlemoyer, and V. Stoyanov. Robust text embeddings for semantic matching. *arXiv preprint arXiv:1907.11692*, 2019.
- [8] N. Reimers and I. Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks. *arXiv preprint arXiv:1908.10084*, 2019.
- [9] S. Wang, X. Chen, L. Guo, and T. X. Han. Multi-scale feature fusion for scene text detection. *arXiv preprint arXiv:1809.08489*, 2018.
- [10] S. Xiao, Z. Liu, Y. Shao, and H. Sun. Bge: Baai general embedding. *arXiv preprint arXiv:2305.15063*, 2023.
- [11] X. Zhang, J. Zhao, and Y. LeCun. Character-level convolutional networks for text classification. *Advances in Neural Information Processing Systems*, 28, 2015.
- [12] Y. Zhang, X. Jiang, Y. Xu, D. Yin, W. X. Zhao, and J.-R. Wen. Tarot: A hierarchical framework with multitask co-pretraining on semi-structured data towards effective person-job fit. *arXiv preprint arXiv:2305.11582*, 2023.

- [13] H. Zhu, X. Li, P. Zhang, G. Li, J. He, W. Li, and H. Luan. Person-job fit: Adapting the right talent for the right job with joint representation learning. *ACM Transactions on Management Information Systems (TMIS)*, 9(3):1–17, 2018.